


0 обратных проходов

3 место из 144

ПРИВАТНЫЙ ЛИДЕРБОРД · 0.8715

КТО ЭТО ГОВОРИТ



Олег Андреев

ML-инженер, Райффайзенбанк

EX-ЯНДЕКС · АНТИФИШИНГ ЯНДЕКС БРАУЗЕРА

Четыре находки, из которых **выросло решение**

12 971 КАРТОЧКА · ДВЕ КАТЕГОРИИ

НАХОДКА 1 · **ЛЕГКОВОСПЛАМЕНЯЮЩИЕСЯ**

Учить почти не на чем

Позитивы сидят копиями друг друга: независимых примеров — десятки, а не сотни.

198

позитивов на 5 502
карточки



78

независимых после
схлопывания копий



11

групп дают половину
всех позитивов

НАХОДКА 2 · **БАД**

БАД закрывается словами

Карточка добавки написана по шаблону, и шаблон видно с первых слов. Языковая модель здесь не нужна.

TF-IDF

НАХОДКА 3 · **РАЗМЕТКА ЛВ**

Одинаковые карточки — разные метки

Каждый пятый позитив ЛВ имеет близнеца с противоположной меткой — **42 из 198**.
Правило вывести нельзя.

ОТНОСИТСЯ

Палочки для розжига IMAGE, 3 упаковки по 6 шт

НЕ ОТНОСИТСЯ

Палочки для розжига IMAGE, 3 упаковки по 6 шт.

НАХОДКА 4 · **ОБЕ КАТЕГОРИИ**

Латиница внутри русских слов

Поиск по слову «спичечница» такую карточку не найдёт.

Сувенир**н**ая **с**пиче**ч**ница (без спичек)

Здесь **очень легко** обмануть себя

КЕЙС 2 · ВАЛИДАЦИЯ


ЛОВУШКА 1 · УТЕЧКА ЧЕРЕЗ ПОЧТИ-ДУБЛИ

78

независимых групп на 198 позитивов ЛВ

ОБУЧЕНИЕ

ПРОВЕРКА



одна группа почти-дублей — по обе стороны

Случайный k-fold рвёт группу копий пополам — и модель узнаёт **товар**, а не правило. Такая проверка завышает F1 по ЛВ на **0.33**.

ЛОВУШКА 2 · ЛИДЕРБОРД КАК ЛИНЕЙКА

Очень мало

позитивов ЛВ на публичной части

ПАБЛИК, ЛВ



весь сигнал лидерборда по ЛВ — эта полоска

Паблик мерит грубее, **чем я улучшаю**.

Лидерборд — не метрика

поэтому качество любого изменения считаю только на собственной локальной валидации

Локальная валидация — единственная точка правды

ОДНА КОНСТРУКЦИЯ НА ОБЕ КАТЕГОРИИ

КАК УСТРОЕНА

Каждый пункт закрывает конкретную ловушку

- 1 Группа почти-дублей неделима**
целиком уезжает в один фолд — модель не встречает на проверке товар, который видела
- 2 Стратификация по (подкатегория × метка)**
18 ячеек вместо одной метки: позитивы разложены по фолдам ровно, а не как повезёт
- 3 Пороги и коэффициенты — на чужих фолдах**
вложено, чтобы отбор не подглядывал в ту часть, на которой его же и меряют

ПРАВИЛО ОТБОРА • ЗАФИКСИРОВАНО ДО ЭКСПЕРИМЕНТОВ

Его работа — не находить улучшения, а не пропускать ложные

- A Считаю качество ранжирования в верхушке списка**
Решение — это верхние 3.3 %. AUC мерит весь порядок, включая хвост, до которого дело не дойдёт.
- B Парный бутстрап по группам**
 Δ , 95 % ДИ и $P(\Delta > 0)$ на одних и тех же карточках, а не два независимых замера
- C Согласие 4 фолдов из 5**
разница в одну-две карточки — это шум, а не улучшение

ВНЕШНИЙ ЦИКЛ • ОЦЕНКА КАЧЕСТВА



☐ обучение ☒ оценка ☐ подбор

ВНУТРЕННИЙ ЦИКЛ • ПОРОГ И КОЭФФИЦИЕНТЫ




обучающая часть делится так же

Доверился локальной валидации — и не прогадал

ТОП-5 · E-CUP 2026 · ЗАДАЧА 2

Одна и та же пятёрка команд на публичной и приватной части, в одном масштабе.

ПУБЛИЧНАЯ ЧАСТЬ · РАЗБРОС 0.136



Как я дошёл до **такого** решения

ИТОГ: ПРИВАТ 0.8715 · 3 МЕСТО ИЗ 144



СТУПЕНЬ 1 · ОПОРА

TF-IDF и логрег

первая отправка, 0.513 на лидерборде

СТУПЕНЬ 2

Текст тремя каналами

название, описание, атрибуты —
раздельно

СТУПЕНЬ 3 · ГЛАВНЫЙ СКАЧОК

getma-4-E4B с примерами

8+8 соседей, подобранных под
карточку

СТУПЕНЬ 4

Калибровка и отсечка


порог — из максимума ожидаемого F1

СТУПЕНЬ 5 · ФИНАЛ

Стек шести каналов

две модели × два промпта, лог-оддсы

Вторая ветка, **БАД** — своя лестница, короче и злее



Что ещё пробовал: 700 экспериментов

КЕЙС 2 · ЗАКРЫТЫЕ ВЕТКИ

ДООБУЧЕНИЕ LLM LoRA-SFT на Qwen3.5-4B 96 % скоров ниже 0.01 СДЕЛАЛО ХУЖЕ	ФОТО КАРТОЧКИ gemma-4-E4B судит изображение 23 из 57 при шансе 0.5 НЕ ИЗМЕНИЛО	РАЗМЕР МОДЕЛИ gemma-4-E2B вместо E4B 0.376 против 0.689 СДЕЛАЛО ХУЖЕ
ДРУГОЕ СЕМЕЙСТВО Qwen3.5-4B рядом с gemma +0.002 от второй модели НЕЗНАЧИМО ЛУЧШЕ	VISION-ЭМБЕДДИНГИ Башня зрения gemma на всех 5502 0 карточек изменилось НЕ ИЗМЕНИЛО	ДРУГОЕ ПРЕДСТАВЛЕНИЕ Qwen3-VL-Embedding-2B и kNN 0.413 против 0.624 СДЕЛАЛО ХУЖЕ
БОЛЬШЕ КОНТЕКСТА Many-shot: 20+20 вместо 8+8 0.214 против 0.689 СДЕЛАЛО ХУЖЕ	БОЛЬШЕ ДАННЫХ Контрфактуальная синтетика 23 удачных из 54 НЕ ИЗМЕНИЛО	ЭВРИСТИКИ · 4 ЗАХОДА Правила и регулярки 1 безопасное из 19 НЕ ИЗМЕНИЛО
ПРОГНАЛ САМИ gemma-4-E4B-it gemma-4-E2B Qwen3.5-4B Qwen2.5-3B Qwen3-VL-Emb-2B зрение gemma mDeBERTa-xnli e5-base rubert-tiny2 TF-IDF + NB ЗЕЛЁНЫМ — В РЕШЕНИИ		

1 ВВОДНЫЕ

 **Размеченные данные**
таблица с метками

 **Карточка товара**
название и описание

идут во все три пути

 **Правило категории**
страница текста

2 КАК СЧИТАЕМ

три пути · БАД и ЛВ — две категории товаров

ОБХОД

 **Точное совпадение с обучающей карточкой**
берём её метку как готовый ответ — мимо моделей

БАД

 **TF-IDF**
слова и символы

 **NB-веса**
различающая сила

 **Логрег**
вероятность

языковые модели не нужны

ЛВ

 **TF-IDF**
два канала

 **kNN**
те же векторы

 **Примеры**
4+4 и 8+8

 **gemma-4-E4B**
два промпта

 **Qwen3.5-4B**
в прод не идёт
без него: -0.0164

 те же TF-IDF-каналы

 **Логрег**
на OOF-скорях каналов

Лестница
под лимит времени

 помеченные блоки оставляют следы —
из них собираем объяснение, следующий слайд

правило — только в промпт языковых моделей

ВЕРДИКТ

SUBMIT

Обрезка топа
фиксированная шапка


ИЛИ

PROD

Порог
с холдаута

Как устроено решение — объяснение

КАЖДЫЙ ВЕРДИКТ — С ДОВОДАМИ



Системная часть **промпта**

70 СЛОВ · ОДНА НА ВСЮ КАТЕГОРИЮ

SYSTEM

gemma-4-e4b · заморожена

Ты производишь историческую разметку маркетплейса: пометил бы разметчик этот товар как легковоспламеняющийся? Общий принцип: **решает то, что физически есть в самом товаре или в его комплекте** (горючее вещество, газ, топливо, пиротехнический заряд, спички), а не то, для чего товар предназначен: пустые устройства для огня размечают как НЕ легковоспламеняющиеся. Ниже даны примеры разметки похожих товаров — ориентируйся прежде всего на них, они отражают реальную конвенцию. Ответ одним словом: да или нет.



+ примеры «да»

ближайшие карточки с меткой 1

4 ИЛИ 8



+ примеры «нет»

ближайшие карточки с меткой 0

СТОЛЬКО ЖЕ

=

да / нет

логиты двух токенов, не текст

Решение **не смотрит на фотографии**

КЕЙС 2 · ТОЛЬКО ТЕКСТ

Пять форм мультимодальности измерены, ни одна не окупилась. А без фото решение ещё и **дешевле держать**.

ОБЪЁМ ДАННЫХ

Скачивать и хранить нечего



9 ГБ → 35 МБ

СКОРОСТЬ · НАШИ ЗАМЕРЫ, БАД

Быстрее учится и быстрее отвечает

	ТОЛЬКО ТЕКСТ	+ ФОТО	ДОЛЬШЕ
ОБУЧЕНИЕ	29 с одно ядро CPU	+31 МИН GPU, проход по фото	×64
ИНФЕРЕНС	1.3 мс на карточку	+0.26 с на каждое фото	×200

ЕДИНСТВЕННЫЙ
МИНУС

Продавец может схитрить

убрать слово из описания и оставить его только на картинке

Что решение стоит в эксплуатации

H100 · ОЦЕНКА ПО ЗАМЕРАМ НА T4

Весы модели не обучаются — только проходы по данным. Всё линейно.

КЛАССИФИКАТОР · ОБУЧЕНИЕ

Один проход модели по базе

$O(n)$

9 МИН
весь трейн

КЛАССИФИКАТОР · ИНФЕРЕНС

Фиксированное число проходов на карточку

$O(n)$

0.1 с
на карточку

ОБЪЯСНЕНИЕ · ОБУЧЕНИЕ

Ничего не учится

$O(n)$

+0 с
к обучению классификатора

ОБЪЯСНЕНИЕ · ИНФЕРЕНС

≈ 11 коротких вопросов к той же модели

$O(n)$

+0.2 с
на карточку

Качество объяснений — на реальных карточках

ВЫБОРКА 40 ИЗ 100

40 случайных объяснений из 100 отложенных карточек, оценка LLM-судьи, пересчёт на 100.

32 релевантны

53 частично

15 нерелевантны

РЕЛЕВАНТНО

ЛВ Шар «Звездный фейерверк»

УБРАТЬ

В описании — воздушный шар фольга («Воздушный шар Звездный фейерверк 78x116см фольга»): по правилу такие не подходят категории, поэтому убираем из категории. По правилу: горючего нет или оно не входит в комплект.

не купился на «фейерверк» в названии

БАД Биотикроз МЕМОРИ, пробиотик

УБРАТЬ

В описании — пищевые продукты не БАД («...серии являются пищевыми продуктами (не БАД) и не имеют ограничений по приему.»): по практике проверки такие не подходят категории, поэтому убираем из категории. По правилу: товар, про который прямо сказано, что он не является БАД.

нашёл «(не БАД)» в середине описания

ЧАСТИЧНО

ЛВ Уголь древесный BOYSCOUT

ОСТАВИТЬ

По правилу категории содержит горючее вещество, газ, топливо или пиротехнический заряд — это про этот товар, поэтому оставляем в категории. Но похожие товары раньше убирали (например, «Трафарет знак пожарной безопасности Огне») — проверьте по фото и описанию.

верно, но похожий товар — трафарет, а не уголь

БАД БАД для иммунитета

ОСТАВИТЬ

Похожие товары раньше оставляли (например, «БАД для иммунитета»), поэтому оставляем в категории.

«БАД» прямо в названии, а довод — только похожие

НЕРЕЛЕВАНТНО

ЛВ Шашка дымовая ДЫМОК

ОСТАВИТЬ

Явных признаков по правилу в описании нет, решение по совокупности мелких, поэтому оставляем в категории. Но похожие товары раньше убирали (например, «Газовая горелка с пьезоподжигом на балло») — проверьте по фото и описанию.

дымовая шашка — явная пиротехника

БАД Креатин, спортивное питание

УБРАТЬ

Явных признаков по правилу в описании нет, решение по совокупности мелких, поэтому убираем из категории. Но «...мышц и безопасного похудения. Биодобавка идеально дополняет спортпит. Ее...» говорит об обратном — посмотрите фото и описание.

«спортивное питание» в названии пропущено

Как это могло бы выглядеть для операциониста

СПОРНАЯ КАРТОЧКА ИЗ ДАТАСЕТА

БАД - карточка 12964

Витамин С в порошке 120 гр
для иммунитета, антиоксидант



Объяснение. Описание спорное: за — речь о питании и рационе и слова «пищевая добавка», против — витамин С этой же марки раньше убрали. Решайте сами — посмотрите состав и маркировку на упаковке.

ОПИСАНИЕ ПРОДАВЦА

подходит не подходит

добавка, которую следует принимать ежедневно. Это водорастворимый витамин, не накапливается в организме, а значит, требует регулярного поступления. Решение — пищевая добавка «Вита-Стандарт» (атлас стандарт) в форме порошка, содержащая аскорбат натрия — некислотная форма витамина С, щадящая для ЖКТ. Преимущества витамина С «Вита-Стандарт»: Высокая усвояемость и биодоступность Подходит как витамин С без вреда желудку — не раздражает слизистую Мягкая форма: аскорбат натрия порошок, рекомендован даже при чувствительном желудке Дозируется точно — ...благодаря мерной ложке Подходит для вегетарианцев Производство... — Россия Не вызывает аллергии, в отличие от чистой аскорбиновой кислоты Также доступны формы: витамин С порошок, витамин С в капсулах, аскорбат натрия вита стандарт, цитрат магния стандарт (в других линиях продукции). Показания к применению витамина С: Плохой иммунитет, частые ОРВИ и простуды Хроническая усталость и стресс Мышечная слабость Сухая кожа, ломкие волосы и ногти Воспаление десен, выпадение зубов Медленное заживление ран и ожогов Детоксикация при курении, алкоголе, ...медикаментах Недостаток витамина С в рационе Повышение энергии Состав...: Аскорбат натрия порошок — чистый

НЕ СМОГЛИ ОПРЕДЕЛИТЬ

Решайте сами

Описание не даёт ясного ответа. Посмотрите состав и маркировку на упаковке и решите сами.

Оставить в категории

A

Отложить

S

Убрать из категории

D

ДОВОДЫ ЗА И ПРОТИВ

подходит

Речь о питании и рационе: «...витамина С в рационе Повышение энергии Состав: Аскорбат натрия...»

подходит

Названо пищевой добавкой: «...регулярного поступления. Решение — пищевая добавка «Вита-Стандарт» (атлас»

НЕ подходит

Похожий товар «Витамин С 60 капсул пищевая добавка...» раньше убрали

ПОХОЖИЕ ТОВАРЫ: 2 ОСТАВИЛИ, 1 УБРАЛИ



Витамин С 60 капсул
пищевая добавка Вита-...

убрали



Магний Стандарт

оставили



SNT Ester-C 120 таблеток
/укрепление организма

оставили

Уверенность модели

здесь не уверена — решает человек

Доводы за и против

зелёный — за категорию, розовый — против

Похожие товары

и что по ним решили раньше

Подсветка в описании

фразы, которые сдвинули решение

ФИНАЛ

Спасибо за **внимание**

ЧТО ДАЛЬШЕ



Пилот

замеряем точность и скорость проверки на карточку



Автоматика там, где модель уверена

ЛВ: 97 % карточек модель решает уверенно — и права в 99.3 % из них



Active learning

спорные карточки — первыми к разметчику, его ответы дообучают каналы



Больше сигналов для оператора

текст с фото упаковки (OCR) и прошлые решения по продавцу



**Как это могло бы выглядеть
для оператора**

наведите камеру телефона

osandreev.github.io/quality_test_page